

Regresión Logística

Es un tipo de modelo estadístico, se usa para problemas de clasificación, en su versión básica es un **clasificador binario**.

Definición del modelo

Este modelo consiste de tres componentes

1. Componente aleatorio

Formado por variables aleatorias y_i que *siguen una Distribución de Bernoulli* con parámetro π_i :

$$y_i \sim Be(\pi_i) \quad i = 1, \dots, n$$

significa, la variable y_i solo puede tomar uno de dos valores posibles (0 o 1).

- π_i es la probabilidad de éxito de la variable y_i , o sea $y_i = 1$.

La función de distribución de Bernoulli se define como:

$$f(y_i) = \pi_i^{y_i} (1 - \pi_i)^{1-y_i} \quad y_i = 0, 1$$

como y_i es un dato conocido, entonces podemos reescribirlo como una función que depende de π_i :

$$f(\pi_i) = \pi_i^{y_i} (1 - \pi_i)^{1-y_i} \quad y_i = 0, 1; \quad i = 1, \dots, n$$

- y_i es la variable respuesta correspondiente a la i -ésima observación.
- n es el número de observaciones.

2. Componente Sistémico

Consiste de *combinaciones lineales*:

$$z_i = \theta_0 1 + \theta_1 x_{i1} + \dots + \theta_{p-1} x_{i(p-1)} \quad i = 1, \dots, n$$

expresado matricialmente, es:

$$z_i = \boldsymbol{\theta}^T \mathbf{x}_i \quad i = 1, \dots, n$$

- $\boldsymbol{\theta}$ es el vector de parámetros desconocidos.
- $\mathbf{x}_i$ es un vector correspondiente a la i -ésima observación. Dicho vector es de tamaño p , tal que en la primera posición contiene 1 y en las siguientes posiciones contiene las $p - 1$ características también conocidos como *regresores* o *predictores*.
- n el número de observaciones.

3. Función enlace

Conecta el componente aleatorio y el componente sistémico a través de la función *Logit*

$$\text{Logit}(\pi_i) = \log\left(\frac{\pi_i}{1 - \pi_i}\right) = z_i \quad i = 1, \dots, n$$

despejando π_i :

$$\pi_i = \frac{e^{z_i}}{1 + e^{z_i}} = \frac{1}{1 + e^{-z_i}}$$

escribiendo $\pi_i = \sigma(z_i)$, es decir, π_i como una función que depende de z_i , obtenemos la **función sigmoide**:

$$\sigma(z_i) = \frac{1}{1 + e^{-z_i}}$$

¿Por qué se usa la función logit?

porque convierte cualquier combinación lineal en una probabilidad.

Entrenamiento

El objetivo es encontrar los mejores parámetros θ_j que se ajusten a los datos para esto vamos a definir la función de máxima verosimilitud.

Estimador de máxima verosimilitud

A partir del componente aleatorio podemos obtener una función de verosimilitud:

$$\begin{aligned}
L(\pi_1, \dots, \pi_n) &= f(\pi_1) \cdot \dots \cdot f(\pi_n) \\
&= \prod_{i=1}^n f(\pi_i) \\
&= \prod_{i=1}^n \pi_i^{y_i} (1 - \pi_i)^{1-y_i}
\end{aligned}$$

Dado que las variables y_i son independientes, entonces la probabilidad conjunta es el producto de las probabilidades marginales.

aplicando $\log(L)$ (logaritmo a la función L), además escribiendo $\log(L) = l$ obtenemos la función *log-likelihood*:

$$l(\pi_1, \dots, \pi_n) = \sum_{i=1}^n [y_i \log(\pi_i) + (1 - y_i) \log(1 - \pi_i)]$$

recordemos que π_i es una *función sigmoide* que depende de z_i , asimismo $z_i = \boldsymbol{\theta}^T \mathbf{x}_i$, entonces la función $l(\pi_1, \dots, \pi_n)$ en realidad es una función que depende de los parámetros θ_j . Por lo tanto, podemos reescribir:

$$l(\pi_1, \dots, \pi_n) = l(\boldsymbol{\theta})$$

De esta forma podemos obtener un **estimador de máxima verosimilitud** para el vector $\boldsymbol{\theta}$:

$$\hat{\boldsymbol{\theta}} = \underset{\boldsymbol{\theta}}{\operatorname{argmax}} l(\boldsymbol{\theta})$$

para definirlo en **términos de minimización**, reescribimos $J(\boldsymbol{\theta}) = -l(\boldsymbol{\theta})$, obteniendo así una **Función de Costo**:

$$J(\boldsymbol{\theta}) = - \sum_{i=1}^n [y_i \log(\sigma(\boldsymbol{\theta}^T \mathbf{x}_i)) + (1 - y_i) \log(1 - \sigma(\boldsymbol{\theta}^T \mathbf{x}_i))]$$

- recordar que $\pi_i = \sigma(\boldsymbol{\theta}^T \mathbf{x}_i)$

Ahora el objetivo es encontrar los parámetros θ_j que **minimicen la función de costo**:

$$\hat{\boldsymbol{\theta}} = \underset{\boldsymbol{\theta}}{\operatorname{argmin}} J(\boldsymbol{\theta})$$

Estimación de los parámetros θ

Existe varios métodos:

- Gradiente descendente
- Newton-Raphson
- IRLS (Iteratively Reweighted Least Squares)

Gradiente Descendente

Mediante este método podemos minimizar la función de costo y encontrar los mejores parámetros θ .

1. Definir una *tasa de aprendizaje* α y un número de *epochs*.
2. Inicializar θ como un **vector columna**, de tamaño p , con valores aleatorios.
3. Iterar el número de *epochs* y actualizar los valores de θ en cada iteración:

```
for epoc to epochs do
     $\theta := \theta - \alpha \nabla J(\theta)$ 
end
```

Luego, el reto es calcular el gradiente de la función de costo $\nabla J(\theta)$.

Gradiente de la función de costo

$$\nabla J(\theta) = \frac{\partial J(\theta)}{\partial \theta}$$

omitiendo el desarrollo del cálculo del gradiente, el resultado expresado en forma matricial, es:

$$\nabla J(\theta) = -X^T(\mathbf{y} - \sigma(X\theta))$$

Recordar:

- $\mathbf{y}$ es un vector columna de tamaño n .
- $X \in \mathbb{R}^{n \times p}$ es una matriz tal que la primera columna es de 1's y el resto corresponde a los regresores.
- θ es un vector columna de tamaño p .
- $\sigma(z) = \frac{1}{1+e^{-z}}$

- *realizar una normalización z-score de los datos, excepto la columna de 1's*

Predicción

Dado un nuevo conjunto de datos X estimar las respuestas $\hat{y}_i$. El proceso es el siguiente, para cada x_i debemos calcular:

$$\sigma(\theta^T \mathbf{x}_i) = \frac{1}{1 + e^{-\theta^T \mathbf{x}_i}} \quad i = 1, \dots, n$$

de forma matricial, todo el conjunto de datos X se calcula de esta manera:

$$\sigma(X\theta) = \frac{1}{1 + e^{-X\theta}}$$

Umbral de probabilidad

Para lograr la clasificación de los datos, se debe considerar un umbral para determinar si $\hat{y}_i$ será 1 o 0, el valor de dicho umbral obviamente debe estar entre 0 y 1, por ejemplo de 0,5:

- $\sigma(\theta^T \mathbf{x}_i) \geq 0.5$ entonces $\hat{y} = 1$
- $\sigma(\theta^T \mathbf{x}_i) < 0.5$ entonces $\hat{y} = 0$

Es importante mencionar que el umbral varia según el problema que se está abordando.